

UNIDAD N° 2

TRANSFORMACIÓN DE VARIABLES PARA EL ANÁLISIS

Diferencias entre limpieza y transformación.
Discretización, codificación y cambio de escala.
Variables derivadas, validación y documentación.

UNIDAD N° 2: PREPARACIÓN Y TRANSFORMACIÓN DE DATOS

INTRODUCCIÓN

La transformación de variables es otra de las actividades que se realizan dentro de la fase de limpieza y preparación de datos del proceso KDD (Knowledge Discovery in Databases). Una vez aplicadas las técnicas de limpieza —el tratamiento de valores nulos y erróneos, la selección de variables y la detección de valores atípicos—, el paso siguiente es la transformación de esos datos.

Transformar variables significa cambiar la forma en que se representan o se utilizan los datos para responder a una necesidad concreta del análisis, sin cambiar el hecho que describen. Suele ser un paso importante porque facilita comparaciones, resume información o prepara las variables para procedimientos posteriores. Sin embargo, no es un paso obligatorio; su necesidad depende del estudio que se quiera realizar y del objetivo al que se desee llegar.

Cabe aclarar que la transformación no corrige por sí sola los problemas de calidad. Solamente modifica la manera en que los datos están representados. Por eso es importante partir de datos ya limpios antes de realizar este paso.

1. DIFERENCIAS ENTRE LIMPIEZA Y TRANSFORMACIÓN

Ambos procesos forman parte de la preparación de datos, pero responden a preguntas diferentes. La limpieza atiende problemas de calidad: valores faltantes, duplicados, formatos incompatibles o datos inválidos. En cambio, la transformación cambia la representación de una variable para que resulte adecuada al análisis que se desea realizar.

	Limpieza	Transformación
Pregunta que responde	¿Este valor es correcto?	¿Esta representación sirve para lo que quiero hacer?
Punto de partida	Datos con errores	Datos ya corregidos
Qué modifica	Valores inválidos, faltantes, duplicados	La escala, el tipo o el nivel de detalle
Criterio de éxito	El dato representa fielmente la realidad	El dato es adecuado para el análisis previsto
Ejemplo	Corregir una fecha imposible como 31/02/2025	Extraer el trimestre de una fecha válida

Durante la transformación de datos es importante tener en cuenta los siguientes puntos:

- **Definir la necesidad:** identificar qué comparación, visualización o procedimiento se busca facilitar.
- **Interpretar la variable:** revisar qué representa, cuál es su escala y qué valores son válidos.
- **Elegir y aplicar la técnica:** seleccionar discretización, codificación, cambio de escala o derivación según el propósito.
- **Documentar:** registrar variable de origen, técnica aplicada, nueva variable y justificación.

2. DIFERENCIAS ENTRE LIMPIEZA Y TRANSFORMACIÓN

La transformación es un paso que se aplica por razones específicas.

2.1. Incompatibilidad de tipos

Muchas veces se requiere cambiar el tipo de una variable, por ejemplo de cualitativa a cuantitativa o a la inversa. Esto suele ser necesario para poder utilizar los algoritmos de la fase de modelado, ya que muchos de ellos exigen que todas las variables a analizar sean de un tipo determinado (algo que veremos más adelante en el curso).

2.2. Incompatibilidad de unidades de medida

Una de las razones más importantes para aplicar la transformación de datos es que las variables suelen estar expresadas en unidades distintas. Como el análisis de datos se basa en el estudio de las variables y de la relación entre ellas, muchas veces habrá que recurrir a transformaciones como la normalización o la estandarización para que todas queden en el mismo rango de valores y puedan compararse entre sí.

2.3. Atenuar el peso de los valores extremos

Los valores atípicos u outliers afectan a las medidas estadísticas sensibles, como la media, el rango o la varianza. La discretización permite atenuar ese efecto. Al agrupar los valores en intervalos, un valor extremo deja de ser un número alejado del resto y pasa a integrar la categoría más alta con el mismo peso que cualquier otro registro de esa categoría.

Por otro lado, el escalado no elimina los valores atípicos, pero permite la estandarización para dejarlos expuestos y poder localizarlos con facilidad, como se explica en el apartado 3.3.2.

2.4. Simplificar la lectura de los resultados

A veces, las transformaciones vuelven los resultados más fáciles de estudiar y de comunicar. También pueden facilitar el cálculo de otras medidas estadísticas y el diseño de gráficos que muestren con mayor claridad lo que se quiere transmitir.

3. TÉCNICAS DE TRANSFORMACIÓN DE DATOS

En este apunte veremos algunas de las transformaciones básicas que se usan para el análisis de datos:

- Discretización
- Numerización
- Escalado
- Otras transformaciones

3.1. Discretización

Cuando hablamos de discretizar nos referimos a agrupar los valores de una variable cuantitativa dentro de un conjunto de intervalos (rangos), de modo que cada registro deje de tener un valor exacto y pase a tener una categoría. La variable resultante es ordinal, es decir sus categorías mantienen un orden, pero pierden la posibilidad de medir las distancias entre ellas.

Aun así se gana legibilidad, estabilidad frente a valores extremos y la posibilidad de aplicar técnicas que exigen variables categóricas. Conviene tener presente que todos los registros que caen dentro de un mismo intervalo pasan a ser indistinguibles entre sí respecto de la nueva variable.

3.1.1. Estrategias para definir puntos de corte

Para discretizar una variable hay que decidir dónde ubicar los puntos de corte. Existen tres criterios de uso extendido:

- **Discretización uniforme (igual amplitud).** Divide el recorrido de la variable en

intervalos de la misma longitud. Con k intervalos, cada uno mide $\frac{X_{\max} - X_{\min}}{k}$. Es la estrategia más simple de explicar y la más fácil de comunicar.

- **Discretización por cuantiles (igual frecuencia).** Ubica los cortes de manera que cada intervalo contenga aproximadamente la misma cantidad de registros. Con cuatro intervalos, los cortes son los cuantiles. Los intervalos resultan de longitudes muy distintas entre sí, pero ninguno queda vacío.

- **Discretización basada en agrupamiento.** Aplica un algoritmo llamado k -medias sobre la variable considerada de forma aislada. Consiste en definir focos o centroides de tal forma que éstos se ubiquen en el centro de un grupo aglomerado de valores. Busca que los valores de cada grupo sean lo más parecidos entre sí, de modo que los cortes tienden a caer donde los datos presentan huecos naturales.

Para comprender mejor los distintos mecanismos de división, tomemos como ejemplo estas doce mediciones de tiempo de respuesta de un servidor, expresadas en milisegundos y ordenadas de menor a mayor:

10 12 13 15 16 18 20 22 25 30 120 400

Se puede observar fácilmente que tiene una distribución asimétrica hacia la derecha (diez valores agrupados entre 10 y 30 y dos casos muy alejados). La media es 58,42 y la mediana 19,00, una diferencia que demuestra analíticamente la asimetría. Aplicando las tres estrategias con cuatro intervalos se obtiene:

Estrategia	Puntos de corte	Registros por intervalo
Uniforme	10 – 107,5 – 205 – 302,5 – 400	10 1 0 1
Cuantiles	10 – 14,5 – 19 – 26,25 – 400	3 3 3 3
Agrupamiento	10 – 19,12 – 72,12 – 260 – 400	6 4 1 1

Los tres resultados son correctos y responden a criterios distintos. Lo que cambia es su utilidad:

- **La estrategia uniforme fracasa en este caso.** Concentra el 83 % de los datos en el primer intervalo y deja el tercero completamente vacío. Una categoría sin registros no aporta información y además rompe cualquier análisis por grupos que se haga después. El motivo es que los cortes se calculan a partir del mínimo y el máximo, y el máximo aquí es un valor atípico que estira artificialmente el recorrido.

- **La estrategia por cuantiles reparte perfectamente** tres registros por cada intervalo, pero hace que el último intervalo vaya de 26,25 a 400, de modo que un tiempo de respuesta de 30 milisegundos y otro de 400 quedan en la misma categoría. Son casos operativamente incomparables y la discretización los volvió idénticos.

- **La estrategia por agrupamiento es la que mejor respeta la forma de los datos.** Separa el grupo compacto de valores bajos en dos categorías y aísla cada uno de los dos casos extremos en su propia categoría. Es la más fiel y también la más difícil de explicar, porque sus cortes (19,12 y 72,12) no son números que alguien elegiría a mano.

3.1.2. Definición de la cantidad de intervalos

Realmente no existe un número correcto de intervalos, aunque cualquier elección presenta ventajas y desventajas. Si elegimos pocos intervalos, borraremos distinciones reales entre los valores; pero, si tomamos muchos intervalos generaremos categorías con tan pocos registros que las conclusiones sobre ellas dejarían de ser representativas. En la práctica se usan entre tres y siete y la decisión se justifica combinando tres criterios:

- El conocimiento del dominio, que a veces impone los cortes. Si la normativa define franjas etarias, esas son las franjas.
- La distribución observada, que puede sugerir cortes naturales donde haya huecos o cambios de densidad.
- La cantidad mínima de registros por categoría que el análisis posterior tolera.

3.2. Numerización de variables categóricas

Numerizar es el camino inverso a discretizar: se parte de una variable cualitativa y se obtienen una o varias variables cuantitativas. Existen dos técnicas principales para realizar esta transformación y la elección entre ellas depende directamente del tipo de variable que se va a transformar.

Recordemos que las variables cualitativas se dividen en dos grupos: nominales y ordinales. Las ordinales tienen la particularidad de poseer un orden, de modo que puede afirmarse que una categoría es mayor, menor o igual que otra. Las nominales no poseen esa característica; sobre ellas solo pueden establecerse igualdades y contarse

frecuencias, pero no compararlas por tamaño ni operar aritméticamente con sus valores.

3.2.1. Numerización 1 a 1

En esta técnica, cada categoría recibe un número que respeta el orden de la variable. Si un nivel de satisfacción tiene cinco grados, de “muy insatisfecho” a “muy satisfecho”, el mapeo natural asigna los números del 1 al 5, siendo 1 “muy insatisfecho” y 5 “muy satisfecho”.

En definitiva, se toma una columna y se la convierte en otra. No se agregan columnas, se conserva el orden y se produce una variable numérica con la que se puede operar. Pero incorpora un supuesto que conviene hacer explícito. Asignar los valores 1, 2, 3, 4 y 5 no solo establece que la quinta categoría es mayor que la primera, sino también que la distancia entre la primera y la segunda es exactamente igual a la distancia entre la cuarta y la quinta, y que la primera está cuatro veces más lejos de la quinta que de la segunda. Esto no siempre constituye un problema, pero en muchos casos puede resultar ser un supuesto incorrecto y por ello hay que tenerlo presente al aplicar la técnica.

Ahora bien, ¿por qué no podemos aplicar esta técnica sobre variables cualitativas nominales? El problema reside en que, al numerizar los valores de una variable nominal, le estamos asignando inevitablemente un orden que originalmente no posee. Si tenemos una variable que sea el color del auto y las opciones son blanco, gris, azul, rojo y negro, no podemos convertirla en valores del 1 al 5 respectivamente, porque estaríamos afirmando que el negro es mayor que el blanco, y eso no tiene ningún sentido. Para transformar este tipo de variables existe la técnica que se describe a continuación.

3.2.2. Numerización 1 a n (one-hot encoding)

Esta transformación es la que corresponde a las variables cualitativas nominales. La idea es generar una columna nueva asociada a cada categoría distinta de la variable original y asignar en ella el valor 1 o 0, según el registro pertenezca o no a esa categoría.

Partiendo de una variable con tres medios de pago:

Registro	medio_pago	pago_efectivo	pago_tarjeta	pago_transferencia
1	Tarjeta	0	1	0
2	Efectivo	1	0	0
3	Transferencia	0	0	1
4	Tarjeta	0	1	0

La virtud de esta representación es que no impone ningún orden: ninguna categoría queda “antes” o “después” de otra. Aunque tiene el inconveniente de que genera tantas columnas como categorías distintas tenga la columna original —de ahí el nombre de numerización 1 a n—, lo que la vuelve poco práctica cuando la variable contiene una cantidad muy alta de valores únicos, como códigos postales, nombres de producto o identificadores de cliente. Ante este problema se pueden agrupar las categorías poco frecuentes en una categoría “otros”, o reducir su cantidad usando un nivel de agregación más alto —en lugar de la localidad, la provincia.

Como regla práctica: si no se puede completar la frase “*esta categoría es mayor que aquella porque...*” con un argumento del dominio, la variable es nominal y corresponde la **numerización 1 a n**.

3.3. Cambio de escala: normalización y estandarización

Las dos técnicas persiguen el mismo objetivo: que variables medidas en unidades distintas puedan compararse. Pero lo consiguen de maneras diferentes y con consecuencias diferentes. Ninguna de las dos modifica la forma de la distribución. Si los datos estaban sesgados antes, siguen sesgados después. Lo que hacen es re-expresar los valores en una escala nueva, definida a partir de la propia distribución de la variable.

3.3.1. Normalización Min-Max

La normalización re-escala los valores usando el mínimo y el máximo observados, de modo que el mínimo pase a valer 0, el máximo pase a valer 1 y el resto se distribuya proporcionalmente entre ambos. Esta transformación puede representarse mediante la siguiente ecuación:

$$x' = \frac{x - X_{\min}}{X_{\max} - X_{\min}}$$

Su ventaja radica en que el resultado queda acotado en el rango $[0; 1]$, lo que

permite comparar valores entre variables. Su debilidad está en la propia fórmula: el denominador depende únicamente del mínimo y del máximo, que son dos valores inestables del conjunto. O sea, este método es muy sensible a los valores extremos.

3.3.2. Estandarización

En este caso se expresa cada valor como la cantidad de desviaciones estándar que lo separan de la media. El resultado tiene media 0 y desviación estándar 1 y responde a la siguiente ecuación:

$$x' = \frac{x - \mu}{\sigma}$$

A diferencia de la normalización, no acota el resultado a ningún intervalo, de modo que los valores atípicos quedan expuestos como valores muy alejados de la media. Esto hace que se comporte mejor frente a ellos e incluso permite identificarlos con rapidez, ya que una regla habitual considera atípico a todo valor que supere 3 unidades en valor absoluto. Es importante tener en cuenta que estandarizar una variable no vuelve normal su distribución, solamente la centra en cero y la re-escala.

Retomando las doce mediciones del apartado 3.1.1, cuya media es 58,42 y cuya desviación estándar es 111,63, ambas transformaciones producen el siguiente resultado:

Valor original	Min-Max	z
10	0,0000	-0,434
12	0,0051	-0,416
13	0,0077	-0,407
15	0,0128	-0,389
16	0,0154	-0,380
18	0,0205	-0,362
20	0,0256	-0,344
22	0,0308	-0,326
25	0,0385	-0,299
30	0,0513	-0,255
120	0,2821	+0,552
400	1,0000	+3,060

La tabla muestra con claridad la diferencia entre ambos métodos. Con Min-Max, los diez valores que van de 10 a 30 milisegundos —el 83 % de los datos— quedan comprimidos entre 0,0000 y 0,0513, es decir en el 5 % del recorrido disponible, mientras que dos observaciones ocupan el resto. Por su parte, la estandarización no aplasta ese grupo contra un límite y ubica el valor extremo en +3,06, donde la regla mencionada lo señala de inmediato.

3.3.3. Criterio de elección

A modo de resumen, detallamos en la siguiente tabla los puntos a considerar para elegir la mejor estrategia de re-escalado.

	Normalización Min-Max	Estandarización z
Rango del resultado	Acotado a [0, 1]	Sin cota; habitualmente entre -3 y 3
Parámetros que usa	Mínimo y máximo	Media y desviación estándar
Sensibilidad a valores extremos	Muy alta: dos observaciones definen toda la escala	Moderada: los extremos afectan la media y la desviación, pero el efecto se reparte
Conviene cuando	El recorrido de la variable es conocido y estable, o el procedimiento posterior exige valores acotados	Hay valores extremos, o se quiere comparar variables por su posición relativa dentro de cada distribución
Evitarla cuando	Hay valores atípicos, o pueden aparecer valores fuera del rango observado	El procedimiento posterior exige un rango acotado

3.4. Otras transformaciones

Las tres familias anteriores son las más comunes, pero también pueden aplicarse otras transformaciones de acuerdo con las necesidades del análisis. A continuación presentamos algunos métodos más de transformación, aunque existen muchas otras formas de transformar las variables.

3.4.1. Derivación

Consiste en calcular una variable nueva combinando otras existentes. Los casos más frecuentes son las sumas, los cocientes y los productos.

- **Totales.** La suma de adultos, niños y bebés produce el tamaño total del

grupo, un concepto que ninguna de las tres columnas expresa por separado.

- **Cocientes.** El precio dividido por el peso produce un precio por unidad de peso. Este tipo de variable es especialmente valiosa porque neutraliza el efecto del tamaño y permite comparar objetos de dimensiones distintas.
- **Productos.** El producto de las tres dimensiones de un objeto produce su volumen, una magnitud con sentido físico que ninguna dimensión aislada tiene.

3.4.2. Separación de atributos

A veces una sola columna contiene varios datos superpuestos. Los identificadores compuestos pueden ser una clave tributaria como el CUIT argentino que codifica en un mismo campo un prefijo que indica el sexo, el número de documento y un dígito verificador. Cada uno de esos componentes es un dato distinto y puede resultar útil por separado.

Lo mismo ocurre con muchos códigos de producto o categorías que combinan letras y números, donde la letra indica una familia y el número un grado dentro de esa familia. En este caso de ejemplo, separarlas en dos columnas permite analizar cada componente por su cuenta.

3.4.3. Tratamiento de variables temporales

Las fechas son una fuente muy rica de variables nuevas. De ellas podemos obtener el año, el mes, el trimestre, el día del mes, el día de la semana y el número de semana, además de indicadores como si la fecha corresponde a un fin de semana o a un feriado. Cada una de esas variables habilita comparaciones que la fecha completa no permite, porque con fechas completas casi no hay repeticiones y, por lo tanto, no hay grupos que comparar.

También se derivan duraciones restando dos fechas: la antelación de una reserva, la antigüedad de un cliente o el tiempo transcurrido entre un pedido y su entrega. Estas variables suelen tener más poder explicativo que las fechas de las que provienen.

3.4.4. Derivación a partir de datos geográficos

De un dato de ubicación se pueden deducir niveles de agregación superiores: de una dirección, el barrio; del barrio, la ciudad; de la ciudad, la provincia. Cada nivel es

una variable categórica nueva con menos categorías que la anterior, lo que la vuelve mucho más manejable para el análisis por grupos y para la codificación.

También pueden incorporarse datos externos asociados a la ubicación, como la población, las condiciones climáticas o los indicadores socioeconómicos. En ese caso ya no se trata de una transformación, sino de un enriquecimiento con otra fuente, con las verificaciones de correspondencia que eso exige.

3.4.5. Agregación

Consiste en cambiar la unidad de análisis. Es decir, pasar de una tabla donde cada fila es una transacción a otra donde cada fila es un cliente, resumiendo las transacciones mediante conteos, sumas o promedios. Es una transformación de la estructura completa y no de una variable, y modifica la cantidad de filas. Por esto no suele ser una estrategia muy usada en la fase de preparación de datos.