UTN
UNIVERSIDAD TECNOLÓGICA NACIONAL

UNIDAD N° 5

DEL ANÁLISIS EXPLORATORIO AL PROBLEMA PREDICTIVO

Del análisis exploratorio a la formulación de problemas predictivos.
Variable objetivo, variables predictoras y momento de predicción.
Selección de predictores y fuga de información.

UNIDAD N° 5: INTRODUCCIÓN AL APRENDIZAJE AUTOMÁTICO Y MINERÍA DE DATOS

INTRODUCCIÓN

El análisis exploratorio de datos permite describir una situación, reconocer patrones, detectar valores atípicos, comparar grupos y formular hipótesis sobre la estructura de un conjunto de datos. Sin embargo, en numerosos contextos profesionales el análisis no termina en la descripción de lo ocurrido. Las organizaciones también necesitan anticipar resultados futuros o desconocidos para orientar decisiones. Ese cambio de propósito conduce desde el análisis exploratorio hacia la formulación de problemas predictivos.

El paso hacia la predicción no consiste simplemente en elegir un algoritmo. Antes de construir un modelo es necesario definir con precisión qué se desea anticipar, cuál es la unidad de análisis, en qué momento se realizará la predicción, qué información estará disponible en ese momento y qué variable representará el resultado de interés. Una formulación incorrecta puede producir modelos técnicamente ejecutables pero conceptualmente inválidos.

En este apunte se desarrollan los conceptos que permiten realizar esa transición de manera ordenada: la diferencia entre describir y predecir, la formulación de una pregunta predictiva, la identificación de la variable objetivo, la selección de variables predictoras y, especialmente, la prevención de la fuga de información. Estos conceptos serán aplicados luego en los notebooks de la Semana 11 y en las etapas posteriores del Trabajo Práctico Integrador.

1. DEL ANÁLISIS EXPLORATORIO A LA PREDICCIÓN

El Análisis Exploratorio de Datos (EDA) tiene como finalidad principal comprender los datos disponibles. A través de tablas, medidas de resumen y visualizaciones se buscan regularidades, diferencias entre grupos, asociaciones, anomalías y posibles explicaciones que orienten preguntas posteriores. Su producto típico es una descripción fundamentada de lo observado.

Un problema predictivo modifica la pregunta central. Ya no se busca solamente describir lo que ocurrió en el conjunto de datos histórico, sino utilizar la información disponible para estimar un resultado que todavía no conocemos en un caso nuevo. La predicción puede consistir, por ejemplo, en anticipar si un cliente abandonará un servicio,

si una reserva hotelera será cancelada o cuál podría ser el valor futuro de una variable cuantitativa.

Enfoque	Pregunta principal	Resultado esperado
Análisis exploratorio	¿Qué ocurrió y qué patrones aparecen?	Tablas, gráficos, medidas e interpretaciones.
Modelado predictivo	¿Qué podría ocurrir en un caso nuevo?	Una predicción, una categoría, una probabilidad o un valor estimado.

Ambos enfoques están relacionados. El modelado predictivo no reemplaza al análisis exploratorio: se apoya en él. Comprender cómo se generaron los datos, qué representan las variables y qué patrones se observan ayuda a formular mejor el problema y a detectar errores que podrían invalidar el modelo. Pero existe una diferencia importante: una asociación descriptiva observada en los datos no es todavía una predicción y tampoco implica por sí misma una relación causal.

Por ejemplo, en un conjunto de datos de abandono de clientes puede observarse que quienes abandonaron el servicio presentan, en promedio, menor antigüedad que quienes permanecieron. Esa afirmación describe un patrón histórico. Transformarla en una pregunta predictiva implica cambiar el foco: ¿podemos utilizar la información disponible de los clientes actuales para anticipar cuáles presentan mayor riesgo de abandono?

2. FORMULAR CORRECTAMENTE UN PROBLEMA PREDICTIVO

Antes de entrenar un modelo conviene expresar el problema en términos concretos. Una pregunta predictiva bien formulada debe indicar qué resultado se desea anticipar, sobre qué tipo de casos se realizará la predicción y en qué momento se necesita obtenerla. Esta definición determina qué datos pueden utilizarse y qué significado tendrá posteriormente el desempeño del modelo.

Una formulación útil puede organizarse alrededor de cinco elementos: la unidad de análisis, el resultado a anticipar, el momento de predicción, la información disponible y el uso que se dará a la predicción.

Elemento	Pregunta orientadora
Unidad de análisis	¿Sobre qué entidad o caso se realizará una predicción: cliente, reserva, transacción, producto?
Resultado	¿Qué queremos anticipar exactamente?
Momento de predicción	¿En qué instante se tomará la información para generar la predicción?
Información disponible	¿Qué variables se conocen legítimamente en ese momento?
Uso de la predicción	¿Qué decisión, acción o análisis podría apoyarse en el resultado?

El momento de predicción merece especial atención. Una misma variable puede ser válida o inválida según cuándo se pretenda realizar la predicción. Si una empresa quiere anticipar el abandono de un cliente treinta días antes de que finalice su contrato, solo podrá utilizar información conocida hasta ese momento. Datos registrados después del abandono no pueden incorporarse, aunque estén presentes en el dataset histórico.

Por esta razón, trabajar con datos históricos requiere reconstruir mentalmente la situación real en la que se utilizaría el modelo. El hecho de que una columna exista en el archivo no significa que hubiera estado disponible en el momento en que la decisión debía tomarse.

3. VARIABLE OBJETIVO: QUÉ RESULTADO QUEREMOS ANTICIPAR

En aprendizaje supervisado, la variable objetivo —también denominada target o respuesta— representa el resultado que el modelo intentará predecir. Durante el entrenamiento se utilizan casos históricos para los cuales ese resultado ya es conocido. El modelo busca aprender relaciones entre la información de entrada y la variable objetivo para luego generar predicciones sobre casos nuevos.

La naturaleza de la variable objetivo permite reconocer, de manera inicial, el tipo de problema. Cuando el objetivo representa una categoría, como cancelar/no cancelar o abandonar/no abandonar, se trata de un problema de clasificación. Cuando el objetivo es un valor numérico, como el monto de una venta o la duración estimada de una entrega, se trata de un problema de regresión. En esta semana interesa principalmente comprender la estructura del problema, no todavía construir los modelos.

Definir la variable objetivo requiere más que seleccionar una columna. Es necesario verificar que esa variable represente realmente el fenómeno que se desea anticipar. Una definición ambigua del objetivo puede producir un modelo que responda correctamente una pregunta distinta de la que la organización necesita resolver.

En el caso de churn, si la finalidad es anticipar el abandono del servicio, la variable Churn puede representar el objetivo. En el caso del Trabajo Práctico Integrador sobre reservas hoteleras, la variable is_canceled representa si una reserva fue finalmente cancelada. En ambos casos el resultado es categórico y, por lo tanto, la formulación corresponde a un problema de clasificación.

4. VARIABLES PREDICTORAS: QUÉ INFORMACIÓN PUEDE UTILIZAR EL MODELO

Las variables predictoras —también llamadas características, atributos, variables de entrada o features— son los datos que se utilizan para intentar anticipar la variable objetivo. En la notación habitual del aprendizaje supervisado, el conjunto de predictores suele representarse mediante X y la variable objetivo mediante Y.

Seleccionar predictores no significa incorporar automáticamente todas las columnas disponibles. Cada variable debería evaluarse desde el punto de vista conceptual y operativo. Una variable puede mostrar una fuerte asociación con el resultado y, aun así, ser inadecuada si no estará disponible al momento de predecir, si contiene información posterior al evento o si su significado cambia entre el período histórico y el contexto donde el modelo será utilizado.

Entre los criterios básicos para evaluar una variable predictora pueden considerarse los siguientes:

- Pertinencia: debe guardar una relación razonable con el problema que se intenta resolver.
- Disponibilidad: su valor debe conocerse en el momento en que se realizará la predicción.
- Calidad: debe tener una definición clara y un nivel de completitud y consistencia compatible con el análisis.
- Estabilidad: conviene considerar si su significado y forma de registro se mantendrán cuando el modelo se utilice.
- Legitimidad: la variable no debe revelar, directa o indirectamente, información del

resultado que todavía no debería conocerse.

También es importante distinguir predicción de causalidad. Un predictor puede ser útil para anticipar un resultado sin ser su causa. Por ejemplo, una característica puede actuar como indicador de un perfil de cliente asociado con mayor riesgo de abandono. Utilizarla para predecir no autoriza a afirmar que modificar esa característica provocará necesariamente un cambio en el resultado.

5. EL MOMENTO DE PREDICCIÓN Y LA DISPONIBILIDAD DE LA INFORMACIÓN

La disponibilidad de una variable depende del instante en que se define la predicción. Este criterio temporal es central para evitar errores de diseño. Antes de seleccionar predictores conviene imaginar una fotografía del sistema en el momento exacto en que el modelo debería emitir su resultado.

Supongamos que un hotel quiere estimar el riesgo de cancelación en el momento en que recibe una reserva. En ese instante pueden conocerse, por ejemplo, el tiempo de anticipación de la reserva (lead_time), el tipo de depósito, el segmento de mercado o antecedentes de cancelaciones previas del cliente. En cambio, no se conoce todavía cuál será el estado final de la reserva ni la fecha en que ese estado quedará registrado.

Si la organización decidiera realizar la predicción en otro momento —por ejemplo, siete días antes de la llegada prevista— podrían existir variables adicionales disponibles. Por lo tanto, una columna no es intrínsecamente 'predictora' o 'no predictora': su validez depende de la pregunta, del proceso real y del momento en que se pretende utilizar el modelo.

6. FUGA DE INFORMACIÓN

Se denomina fuga de información (data leakage) a la utilización, durante el desarrollo de un modelo, de información que no estaría disponible de manera legítima en el momento real de realizar la predicción o que revela directa o indirectamente el resultado que se intenta anticipar. La fuga puede hacer que el modelo parezca mucho mejor de lo que realmente sería cuando se utilice con casos nuevos.

El problema es especialmente engañoso porque el código puede ejecutarse sin errores y las métricas obtenidas pueden ser muy altas. Sin embargo, ese desempeño no representa una capacidad genuina de predicción: el modelo está recibiendo información que, en la práctica, pertenece al futuro o contiene parte de la respuesta.

6.1. FORMAS FRECUENTES DE FUGA DE INFORMACIÓN

Una primera forma aparece cuando se utilizan variables registradas después de ocurrido el evento. Si queremos anticipar el abandono de un cliente, una fecha de baja creada una vez que el abandono ya ocurrió no puede utilizarse como predictor. La variable puede explicar perfectamente el pasado, pero no estaría disponible cuando se necesita anticipar el resultado.

Otra forma ocurre cuando una variable es una transformación, resumen o consecuencia directa de la variable objetivo. Aunque tenga un nombre diferente, puede contener la respuesta de manera encubierta. También puede producirse fuga cuando se calculan ciertos parámetros de preparación utilizando información de datos que deberían permanecer reservados para evaluar el modelo. Esta última situación se retomará cuando se trabaje con la separación entre datos de entrenamiento y de prueba.

En esta etapa de la materia interesa especialmente reconocer la forma más intuitiva y frecuente: utilizar como predictor información que solo se conoce después del resultado. La pregunta práctica que debe acompañar la selección de cada variable es sencilla: ¿este dato estaría disponible en el momento real en que necesito realizar la predicción?

Pregunta	Si la respuesta es...	Consecuencia
¿La variable se conoce antes del resultado?	No	No debería utilizarse como predictor.
¿La variable contiene o deriva directamente del resultado?	Sí	Existe riesgo de fuga de información.
¿La variable estará disponible cuando el modelo se use?	No	El modelo no podrá reproducir ese desempeño en la práctica.

7. EJEMPLO 1: ABANDONO DE CLIENTES (CHURN)

El dataset utilizado en las actividades de la Semana 11 permite ilustrar la transición desde una observación exploratoria hacia un problema predictivo. Supongamos que el EDA muestra que los clientes que abandonaron el servicio presentan, en promedio, menor antigüedad y determinadas características contractuales con mayor frecuencia que quienes permanecieron.

Ese hallazgo no constituye todavía un modelo. Para formular el problema predictivo se podría expresar la pregunta de la siguiente manera: ¿qué clientes actuales presentan

mayor riesgo de abandonar el servicio? La unidad de análisis es el cliente; la variable objetivo es Churn; y las variables predictoras deben corresponder a información disponible antes de conocer si el cliente abandonará.

Variable o información	Disponibilidad al predecir	Uso como predictor
Antigüedad del cliente	Disponible	Podría considerarse.
Tipo de contrato	Disponible	Podría considerarse.
Cargo mensual	Disponible	Podría considerarse.
Servicios contratados	Disponible	Podrían considerarse.
Fecha de baja registrada después del abandono	No disponible	No corresponde: produce fuga de información.

El ejemplo muestra que la selección no depende únicamente de la capacidad estadística de una variable para separar grupos. Una fecha de baja podría estar fuertemente relacionada con Churn, pero esa relación carece de utilidad predictiva si la fecha solo existe después de que el evento ya ocurrió. Un modelo que la utilizara respondería una pregunta retrospectiva, no la pregunta prospectiva que se intenta resolver.

8. EJEMPLO 2: CANCELACIÓN DE RESERVAS HOTELERAS

El mismo razonamiento se aplica al caso Hotel Booking Demand utilizado en el Trabajo Práctico Integrador. El propósito predictivo puede formularse como anticipar si una reserva será cancelada. La unidad de análisis es cada reserva y la variable objetivo es is_canceled.

Entre las variables que podrían analizarse como predictoras se encuentran, según el momento definido para la predicción, el tiempo de anticipación de la reserva (lead_time), el tipo de depósito, el segmento de mercado, el tipo de cliente, la cantidad de cancelaciones previas o determinadas características de la estadía. La pertinencia final de cada variable debe evaluarse considerando su disponibilidad real.

En cambio, variables como reservation_status y reservation_status_date requieren especial cuidado. Si el estado final de la reserva y la fecha en que ese estado se registra se conocen únicamente después de que la reserva fue cancelada o concretada, incorporarlas para predecir is_canceled introduciría información del resultado. El modelo podría aprender una relación aparentemente perfecta, pero esa información no existiría

en el momento en que se pretende anticipar la cancelación.

Este ejemplo también permite advertir que el momento de predicción debe quedar explícito. Si la organización quiere predecir en el instante de creación de la reserva, solo podrá utilizar información disponible en ese instante. Si la predicción se realiza más adelante, algunas variables actualizadas durante el proceso podrían estar disponibles. La definición temporal del problema determina, por lo tanto, el conjunto legítimo de predictores.

9. DE UN HALLAZGO EXPLORATORIO A UNA PREGUNTA PREDICTIVA

Una práctica útil consiste en transformar deliberadamente conclusiones descriptivas en preguntas predictivas. El objetivo no es afirmar que toda asociación deba utilizarse para predecir, sino aprender a reconocer el cambio de propósito.

Hallazgo exploratorio	Posible pregunta predictiva
Los clientes que abandonaron presentan menor antigüedad promedio.	¿Qué clientes actuales tienen mayor riesgo de abandonar?
Las cancelaciones son más frecuentes en determinados segmentos de mercado.	¿Qué reservas actuales presentan mayor probabilidad de cancelación?
Algunos grupos de transacciones concentran más casos de fraude.	¿Qué nuevas transacciones deberían considerarse de mayor riesgo?

La pregunta predictiva debe ser operativa. Expresiones vagas como 'predecir mejor' o 'usar inteligencia artificial para conocer a los clientes' no definen qué variable se quiere anticipar, ni sobre qué casos, ni cuándo. Una formulación precisa permite decidir luego qué datos son adecuados y cómo evaluar el modelo.

10. LISTA DE CONTROL ANTES DE COMENZAR A MODELAR

Antes de pasar a la construcción de un modelo conviene poder responder claramente las siguientes preguntas. Esta lista funciona como una verificación conceptual previa al trabajo técnico:

- ¿Cuál es el problema que se intenta resolver y por qué una predicción podría resultar útil?
- ¿Cuál es la unidad de análisis sobre la que se generará cada predicción?
- ¿Cuál es la variable objetivo y qué representa exactamente?
- ¿El resultado esperado corresponde a una categoría o a un valor numérico?

- ¿En qué momento se realizará la predicción en el contexto real?
- ¿Qué variables estarán disponibles en ese momento?
- ¿Alguna variable contiene información posterior al resultado o lo revela de manera directa o indirecta?
- ¿Los predictores seleccionados tienen una interpretación coherente con el problema?
- ¿Las conclusiones se formulan como predicciones y no como afirmaciones causales que los datos no permiten sostener?

Resolver estas preguntas antes del entrenamiento evita numerosos problemas posteriores. Un buen modelo predictivo comienza con una buena definición del problema y con un conjunto de datos construido de acuerdo con esa definición.

11. SÍNTESIS

El paso desde el análisis exploratorio hacia el modelado predictivo implica un cambio de pregunta. El EDA ayuda a comprender qué ocurrió y qué patrones aparecen en los datos; el modelado predictivo intenta anticipar un resultado desconocido para casos nuevos. Ambos procesos se complementan, pero no deben confundirse.

En los problemas supervisados, la variable objetivo representa el resultado que se quiere anticipar y las variables predictoras aportan la información utilizada para generar la predicción. La selección de predictores debe considerar no solo su relación con el resultado, sino también su disponibilidad, calidad, estabilidad y legitimidad en el momento real de uso.

La fuga de información constituye uno de los errores conceptuales más importantes en el diseño de un problema predictivo. Ocurre cuando se incorpora información que no estaría disponible al momento de predecir o que contiene parte de la respuesta. Puede producir resultados aparentemente excelentes durante el desarrollo y, al mismo tiempo, un modelo inútil en la práctica.

Por ello, antes de entrenar cualquier modelo conviene fijar con claridad el momento de predicción y preguntar, para cada variable: ¿este dato estaría disponible cuando tenga que realizar la predicción? Esta regla sencilla permite distinguir información histórica útil de información que introduce una ventaja artificial e inválida.

BIBLIOGRAFÍA DE REFERENCIA

Han, J., Kamber, M. y Pei, J. (2011). Data Mining: Concepts and Techniques (3.ª ed.). Morgan Kaufmann.

James, G., Witten, D., Hastie, T., Tibshirani, R. y Taylor, J. (2023). An Introduction to Statistical Learning: with Applications in Python. Springer.

Kuhn, M. y Johnson, K. (2013). Applied Predictive Modeling. Springer.