UTN
UNIVERSIDAD TECNOLÓGICA NACIONAL

UNIDAD N° 5

INTERPRETACIÓN, GENERALIZACIÓN Y LIMITACIONES DE LOS MODELOS

Interpretación de predicciones y probabilidades. Generalización, datos de prueba y sobreajuste. Errores, sesgos, cambios de contexto y utilidad de los modelos.

UNIDAD N° 5: INTRODUCCIÓN AL APRENDIZAJE AUTOMÁTICO Y MINERÍA DE DATOS

INTRODUCCIÓN

Construir un modelo predictivo es solo una parte del trabajo de análisis de datos. Una vez obtenidas las predicciones, comienza una tarea igualmente importante: interpretarlas, analizar sus errores y limitaciones y decidir si el modelo resulta suficientemente útil para el contexto en el que se pretende utilizar. Un resultado generado por un algoritmo no constituye por sí mismo una conclusión ni una decisión.

Durante la Semana 11 se introdujo la formulación de problemas predictivos y se construyó un primer modelo de clasificación sencillo. En esta etapa el foco se desplaza hacia la lectura crítica de lo que ese modelo produce. Para ello es necesario distinguir entre la categoría predicha, la probabilidad estimada, la interpretación de ese resultado y la eventual decisión que una organización podría tomar a partir de la información disponible.

Este apunte desarrolla los conceptos necesarios para realizar esa lectura de manera responsable: interpretación de predicciones, incertidumbre, separación entre datos de entrenamiento y prueba, generalización, sobreajuste, errores de clasificación, variables ausentes, sesgos, cambios de contexto y utilidad práctica. El objetivo no es introducir técnicas avanzadas de evaluación, sino construir una base conceptual que permita comprender por qué un modelo puede funcionar técnicamente y, aun así, resultar insuficiente o poco confiable para orientar decisiones.

1. DE LA PREDICCIÓN A LA INTERPRETACIÓN

Un modelo de clasificación recibe información sobre un caso y produce una salida. En un problema binario, esa salida suele expresarse como una categoría —por ejemplo, “abandona” o “no abandona”— y puede estar acompañada por una probabilidad estimada para la clase de interés. La existencia de una predicción no significa que el resultado sea verdadero ni que la acción posterior sea evidente.

Conviene separar cuatro niveles que suelen confundirse: el resultado producido por el modelo, la probabilidad asociada, la interpretación que se hace de ese resultado y la decisión que eventualmente se toma. Cada nivel agrega información y requiere supuestos adicionales.

Nivel	Pregunta orientadora	Ejemplo
Predicción	¿Qué clase asignó el modelo?	El modelo predice que el cliente podría abandonar.
Probabilidad estimada	¿Con qué intensidad o confianza relativa aparece esa clase?	Probabilidad estimada de abandono: 0,78.
Interpretación	¿Qué significa ese resultado dentro del problema?	El cliente presenta un perfil similar a otros casos históricos de abandono.
Decisión	¿Qué acción conviene tomar, considerando costos, riesgos y contexto?	Evaluar una acción de retención, no necesariamente ejecutarla de manera automática.

La interpretación exige recuperar el contexto. Una probabilidad alta puede indicar que el modelo reconoce un patrón frecuente en los datos históricos, pero no demuestra que el resultado vaya a ocurrir. Tampoco demuestra que las variables utilizadas sean causas del fenómeno. El modelo resume relaciones aprendidas a partir de la información disponible; esas relaciones deben evaluarse críticamente antes de actuar.

2. PROBABILIDAD ESTIMADA E INCERTIDUMBRE

En muchos modelos de clasificación, además de una categoría se obtiene una probabilidad estimada. Esta probabilidad permite ordenar casos según el grado con que el modelo los asocia a una clase. Sin embargo, no debe interpretarse como una certeza matemática acerca del futuro. Es una estimación construida a partir del modelo, los datos y los supuestos utilizados.

Los casos con probabilidades cercanas a los extremos suelen representar decisiones más claras para el modelo, mientras que los casos cercanos al punto de corte utilizado para asignar una categoría son más inciertos. Esta incertidumbre es relevante porque dos casos clasificados de la misma manera pueden tener probabilidades muy diferentes y, por lo tanto, requerir distintos niveles de cautela.

El punto de corte transforma una probabilidad en una categoría. En muchos ejemplos introductorios se utiliza 0,5, pero ese valor no es una ley universal. En aplicaciones reales, el umbral puede depender del costo relativo de los errores y de los objetivos de la organización. En esta materia alcanza con comprender que la categoría predicha es una simplificación de una estimación probabilística y que las decisiones no deberían

descansar únicamente en esa etiqueta.

3. DATOS DE ENTRENAMIENTO Y DATOS DE PRUEBA

Para analizar si un modelo puede funcionar más allá de los casos con los que fue construido, es necesario diferenciar los datos utilizados para aprender de los datos reservados para evaluar su comportamiento. Los primeros se denominan datos de entrenamiento; los segundos, datos de prueba.

Durante el entrenamiento, el algoritmo ajusta sus reglas o parámetros utilizando ejemplos cuyo resultado es conocido. Si evaluáramos el modelo únicamente sobre esos mismos casos, podríamos obtener una impresión excesivamente optimista: el modelo ya tuvo acceso a esa información durante el proceso de aprendizaje. Por esta razón se reserva un conjunto de casos que no participa del entrenamiento.

Conjunto	Función	Qué permite observar
Entrenamiento	Ajustar el modelo y aprender patrones a partir de datos históricos.	Cómo se adapta el modelo a los casos que utiliza para aprender.
Prueba	Evaluar el modelo sobre observaciones no utilizadas durante el entrenamiento.	Una primera aproximación a su comportamiento frente a casos nuevos.

La separación entre entrenamiento y prueba no garantiza por sí sola un buen modelo, pero introduce una condición básica de evaluación. Permite formular una pregunta esencial: ¿el patrón aprendido conserva utilidad cuando el modelo enfrenta observaciones que no utilizó para ajustarse?

4. GENERALIZACIÓN

La generalización es la capacidad de un modelo para mantener un desempeño razonable frente a datos nuevos provenientes del mismo tipo de problema para el cual fue construido. Un modelo útil no debería limitarse a reproducir los casos de entrenamiento: debe captar regularidades suficientemente estables como para aplicarlas a observaciones que todavía no vio.

La idea de generalización obliga a distinguir entre aprender un patrón y memorizar ejemplos. Si un árbol de decisión reproduce con gran detalle particularidades del conjunto de entrenamiento, puede parecer muy preciso en esos datos y, sin embargo, fallar cuando se enfrenta a nuevos casos. En cambio, un modelo que identifica relaciones más

estables puede cometer algunos errores en entrenamiento y funcionar mejor fuera de él.

En esta etapa se utiliza el conjunto de prueba como una primera aproximación a la generalización. No se pretende desarrollar todavía procedimientos avanzados de validación; interesa comprender el principio: el desempeño relevante de un modelo no es únicamente el que muestra sobre los datos con los que aprendió, sino el que puede sostener cuando se lo utiliza en casos no vistos.

5. SOBREAJUSTE

Se habla de sobreajuste cuando un modelo se adapta en exceso a los datos de entrenamiento, incluyendo detalles accidentales, ruido o particularidades que no representan patrones generales del problema. El modelo puede producir resultados muy buenos sobre los datos conocidos y perder desempeño al aplicarse a observaciones nuevas.

El sobreajuste no significa que el algoritmo “funcione mal” desde el punto de vista técnico. Por el contrario, muchas veces aparece precisamente porque el modelo dispone de suficiente flexibilidad para ajustarse demasiado bien al conjunto de entrenamiento. El problema es que parte de lo aprendido no se repite fuera de ese conjunto.

Una señal conceptual de sobreajuste aparece cuando existe una diferencia marcada entre el desempeño observado en entrenamiento y el obtenido en datos no utilizados para aprender. En esta materia no se requiere aplicar técnicas avanzadas para corregirlo; alcanza con reconocer la idea y comprender por qué la evaluación sobre datos de prueba es necesaria.

Situación	Lectura inicial
Buen desempeño en entrenamiento y también en prueba	El patrón aprendido podría generalizar razonablemente dentro del contexto evaluado.
Muy buen desempeño en entrenamiento y deterioro importante en prueba	Puede existir una señal de sobreajuste.
Desempeño deficiente en ambos conjuntos	El modelo o la información disponible pueden ser insuficientes para el problema.

Estas lecturas son orientativas y no deben convertirse en reglas automáticas. El tamaño de los datos, la calidad del muestreo, la definición del problema y la estabilidad del contexto también influyen en la interpretación.

6. LOS ERRORES DE CLASIFICACIÓN NO SON EQUIVALENTES

En una clasificación binaria pueden producirse dos tipos conceptualmente diferentes de error. El modelo puede predecir la clase positiva cuando el resultado real es negativo, o puede predecir la clase negativa cuando el resultado real es positivo. Más adelante estos errores se organizarán formalmente mediante la matriz de confusión; en esta etapa interesa comprender sus consecuencias.

En un problema de churn, por ejemplo, considerar en riesgo a un cliente que no pensaba abandonar puede llevar a ofrecer un beneficio innecesario. En cambio, no detectar a una persona que efectivamente abandona puede implicar perder la oportunidad de realizar una acción de retención. Ninguno de los errores es “siempre peor”: su importancia depende del objetivo, los costos y el contexto.

Esta diferencia muestra por qué una medida global de aciertos no siempre alcanza para decidir si un modelo es útil. Dos modelos con resultados generales similares pueden cometer errores de distinta naturaleza y producir consecuencias muy diferentes. La evaluación debe relacionar el desempeño técnico con el problema concreto.

7. INFORMACIÓN AUSENTE, CALIDAD DE DATOS Y SESGOS

Los modelos solo pueden aprender a partir de las variables que reciben. Si una característica importante del fenómeno no está registrada, el modelo no puede incorporarla directamente. En un problema de abandono de clientes podrían faltar, por ejemplo, datos sobre experiencias de atención, problemas técnicos recientes o cambios en la situación económica del usuario.

La ausencia de información relevante no invalida automáticamente un modelo, pero limita lo que puede explicar o anticipar. También pueden existir errores de medición, registros incompletos, categorías mal definidas o diferencias sistemáticas en la forma en que se recopilan los datos. Estos problemas pueden trasladarse a las predicciones.

El término sesgo puede utilizarse en distintos sentidos. En este contexto introductorio interesa reconocer que los datos históricos no son una representación perfecta de la realidad: reflejan decisiones previas, formas de medición, poblaciones observadas y procesos institucionales. Por ello, el modelo puede reproducir desigualdades o patrones problemáticos presentes en esos datos.

8. DIFERENCIAS ENTRE GRUPOS Y LECTURA RESPONSABLE

Comparar errores entre grupos puede ayudar a detectar preguntas relevantes. Si un modelo se equivoca con distinta frecuencia para diferentes subpoblaciones, conviene investigar las razones. Sin embargo, una comparación descriptiva no constituye por sí sola una evaluación completa de equidad y tampoco demuestra que pertenecer a un grupo cause el resultado.

Las diferencias pueden deberse a tamaños de muestra distintos, calidad desigual de la información, relaciones diferentes entre variables o procesos históricos específicos. La interpretación responsable exige evitar conclusiones causales rápidas y, cuando el contexto lo requiera, profundizar el análisis con herramientas adecuadas.

En esta materia el objetivo es desarrollar una actitud crítica: reconocer que una predicción debe revisarse no solo en términos de funcionamiento general, sino también considerando quiénes pueden verse afectados, qué información falta y qué consecuencias tendría utilizar el modelo.

9. CAMBIOS DE CONTEXTO

Un modelo se construye a partir de datos generados en un período y bajo determinadas condiciones. Si esas condiciones cambian, las relaciones aprendidas pueden dejar de representar adecuadamente el problema. Un patrón histórico útil hoy puede perder valor después de una modificación tecnológica, económica, comercial o institucional.

En un servicio por suscripción, por ejemplo, una nueva política de precios, un cambio en la competencia o una modificación importante de la plataforma puede alterar las razones por las cuales los clientes abandonan. En un hotel, cambios en las políticas de cancelación, en los canales de reserva o en el perfil de los huéspedes pueden modificar el comportamiento observado.

Por esta razón, la utilidad de un modelo no es permanente. Los resultados deben interpretarse dentro del contexto en que fueron obtenidos y, en aplicaciones reales, el comportamiento del modelo debe seguirse a lo largo del tiempo. En esta asignatura alcanza con reconocer que el cambio de contexto es una fuente relevante de limitación.

10. UN MODELO QUE PREDICE NO NECESARIAMENTE RESUELVE EL PROBLEMA

La calidad predictiva y la utilidad de una decisión son cuestiones relacionadas pero diferentes. Incluso un modelo razonable puede dar lugar a una acción costosa, impracticable o poco efectiva. Por ello, transformar predicciones en decisiones requiere incorporar información que el algoritmo no contiene: costos, beneficios, capacidad operativa, restricciones, riesgos y objetivos de la organización.

Supongamos que una empresa identifica 300 clientes con riesgo de churn y ofrece a cada uno un beneficio de $20. La campaña cuesta $6.000. Si solo 180 de esas personas realmente habrían abandonado y la acción logra retener a 90 clientes que aportan $70 cada uno, el ingreso preservado es $6.300 y el resultado neto estimado es apenas $300. La predicción puede ser razonable y, aun así, la intervención tener un impacto escaso.

Este ejemplo muestra que la decisión final no puede delegarse automáticamente en el modelo. La predicción es un insumo para la decisión, no la decisión misma. La utilidad debe evaluarse en relación con las consecuencias de actuar y de no actuar.

11. PREDICCIÓN NO ES CAUSALIDAD

Un modelo predictivo busca anticipar resultados. Para hacerlo puede utilizar variables asociadas al fenómeno sin que esas variables sean necesariamente sus causas. Una característica puede ser útil para identificar un perfil de riesgo y, al mismo tiempo, no constituir una palanca sobre la cual intervenir.

Por ejemplo, si cierto tipo de contrato aparece asociado a una mayor probabilidad de churn, el modelo puede utilizar esa información para reconocer casos. Eso no demuestra que cambiar el contrato produzca por sí solo una reducción del abandono. Para sostener una afirmación causal se necesita un diseño de análisis diferente.

Mantener esta distinción evita una interpretación frecuente pero incorrecta: pasar de “esta variable ayuda a predecir” a “si modificamos esta variable, cambiaremos el resultado”. La primera afirmación puede derivarse de un modelo predictivo; la segunda requiere evidencia causal adicional.

12. EJEMPLO INTEGRADO: CHURN

El caso de churn permite reunir los conceptos anteriores. La empresa quiere anticipar qué clientes presentan mayor riesgo de abandono. Para ello construye un modelo con datos históricos y reserva una parte de los casos para prueba. El modelo produce una

categoría y una probabilidad para cada cliente.

Antes de utilizar esos resultados, conviene revisar varias preguntas. ¿El desempeño sobre los datos de prueba es razonablemente consistente con lo observado durante el entrenamiento? Si existiera una caída importante, podría haber una señal de sobreajuste. ¿Qué tipos de errores comete el modelo y cuál de ellos genera mayores costos? ¿Faltan variables relevantes? ¿El contexto actual es comparable con el período histórico? ¿La acción de retención propuesta tiene un beneficio esperado superior a su costo?

La respuesta a estas preguntas no surge de una única métrica. Requiere combinar evidencia técnica, conocimiento del negocio y una interpretación responsable de los límites del modelo.

13. CONEXIÓN CON EL TRABAJO PRÁCTICO INTEGRADOR

En el Trabajo Práctico Integrador, el problema consiste en anticipar la cancelación de reservas hoteleras utilizando is_canceled como variable objetivo. En la Entrega 5 se construye un primer modelo de clasificación y se generan predicciones sobre datos de prueba. En la Entrega 6 se evaluará formalmente ese modelo mediante una matriz de confusión y métricas específicas de clasificación.

Los conceptos desarrollados en este apunte permiten interpretar esa transición. Separar entrenamiento y prueba proporciona una primera aproximación a la generalización; comparar el comportamiento del modelo en datos no utilizados para aprender ayuda a reconocer posibles señales de sobreajuste; y analizar los errores en el contexto hotelero permite decidir qué consecuencias pueden tener los falsos positivos y los falsos negativos.

También será necesario considerar las limitaciones del dataset y del contexto. Un modelo construido con información histórica puede perder utilidad si cambian las políticas de cancelación, los canales de reserva o el perfil de los clientes. Por ello, la evaluación no debe reducirse a calcular métricas: debe culminar en una conclusión sobre la utilidad y los límites del modelo.

14. LISTA DE CONTROL PARA INTERPRETAR UN MODELO

Antes de transformar una predicción en una conclusión o una decisión, conviene revisar las siguientes preguntas:

- ¿La predicción se está interpretando como una estimación y no como una certeza?

- ¿Se distingue entre categoría predicha, probabilidad estimada e intervención posterior?
- ¿El modelo fue evaluado sobre datos que no utilizó para aprender?
- ¿El desempeño en datos nuevos es compatible con una capacidad razonable de generalización?
- ¿Existen señales de que el modelo podría estar sobreajustado a los datos de entrenamiento?
- ¿Qué tipos de errores produce y qué consecuencias tiene cada uno en el contexto?
- ¿Faltan variables importantes o existen problemas de calidad en los datos?
- ¿Se observan diferencias entre grupos que merezcan investigación adicional?
- ¿El contexto actual es comparable con aquel en que se generaron los datos históricos?
- ¿La predicción aporta una acción útil después de considerar costos, beneficios, riesgos y restricciones?
- ¿Se evita interpretar una asociación predictiva como una relación causal?

15. SÍNTESIS

Interpretar un modelo predictivo exige ir más allá de comprobar que el código funciona y produce resultados. Una predicción es una estimación construida a partir de datos históricos y debe analizarse dentro del contexto del problema. La probabilidad asociada expresa información adicional sobre la salida del modelo, pero tampoco constituye una certeza ni una orden automática de acción.

La separación entre entrenamiento y prueba permite observar cómo se comporta el modelo frente a casos que no utilizó para aprender. Esa evaluación ofrece una primera aproximación a la generalización. Cuando el desempeño es muy bueno en entrenamiento y se deteriora de manera importante en datos nuevos, puede existir una señal de sobreajuste: el modelo aprendió particularidades del conjunto de entrenamiento que no se sostienen fuera de él.

Los errores, la información ausente, los sesgos, las diferencias entre grupos y los cambios de contexto también condicionan la utilidad del modelo. Además, una predicción técnicamente razonable puede conducir a una decisión poco conveniente si no se consideran costos, beneficios, riesgos y objetivos. Por ello, el valor de un modelo no depende únicamente de su capacidad para predecir, sino también de la calidad de la interpretación y del uso responsable de sus resultados.

En la Unidad N° 6 estos principios se complementarán con herramientas formales de evaluación de clasificación. La matriz de confusión y las métricas accuracy, precision, recall y F1-score permitirán describir con mayor precisión el desempeño del modelo y vincular sus errores con las necesidades concretas del problema.

BIBLIOGRAFÍA DE REFERENCIA

Han, J., Kamber, M. y Pei, J. (2011). Data Mining: Concepts and Techniques (3.ª ed.). Morgan Kaufmann.

James, G., Witten, D., Hastie, T., Tibshirani, R. y Taylor, J. (2023). An Introduction to Statistical Learning: with Applications in Python. Springer.

Kuhn, M. y Johnson, K. (2013). Applied Predictive Modeling. Springer.

Kabacoff, R. I. (2019). Data Science Using Python and R. CRC Press.